

Towards a Categorical Foundation of Deep Learning: A Survey

Una rassegna di approcci categorici al *deep learning*

Francesco Riccardo Crescenzi

12 settembre 2024

Alma mater studiorum - Università di Bologna
CdL in Matematica

**We are in an AI summer,
but is winter coming?**

Mancano fondamenta teoriche:

- **design ad hoc** (Gavranović, 2024)

Mancano fondamenta teoriche:

- **design ad hoc** (Gavranović, 2024)
- **complessità fine a se stessa** (Rahimi, 2017)

Mancano fondamenta teoriche:

- **design ad hoc** (Gavranović, 2024)
- **complessità fine a se stessa** (Rahimi, 2017)
- **fragilità** (Gavranović, 2024)

La ricerca viene rallentata da:

- **research debt** (Olah e Carter, 2017)

La ricerca viene rallentata da:

- **research debt** (Olah e Carter, 2017)
- **mancata replicabilità** (Raff, 2019)

Teoria delle categorie:

una lingua franca della matematica e delle scienze

La teoria delle categorie studia strutture e relazioni, e può essere vista come un'estensione del celebre *Erlangen Programme*.

La teoria delle categorie può essere applicata con successo anche in fisica, informatica, chimica... ovunque ci sia **composizionalità** (Fong e Spivak, 2018).

- **lenti parametriche** (Gavranović, 2024, Cruttwell et al., 2022)
- **categorical deep learning** (Gavranović et al., 2024)
- **integral transforms** (Dudzik e Veličković, 2022, Dudzik et al., 2024)
- **functor learning** (Gavranović, 2019, Sheshmani e You, 2021, Chytas et al., 2024)
- **compositional distributional model of meaning** (Clark e Pulman, 2007, Coecke et al., 2010, Lewis, 2019)
- **neural circuit diagrams** (Abbott, 2023)
- **string diagrams with universal approximators** (Khatri et al., 2024)

- **lenti parametriche**
- **categorical deep learning**
- integral transforms
- functor learning
- compositional distributional model of meaning
- neural circuit diagrams
- string diagrams with universal approximators

Lenti parametriche

per modellare il gradient-based learning

Il gradient-based learning segue tre principi fondamentali:

- **parametricità**

Il gradient-based learning segue tre principi fondamentali:

- **parametricità**
- **bidirezionalità**

Il gradient-based learning segue tre principi fondamentali:

- **parametricità**
- **bidirezionalità**
- **differenziabilità**


DEFINIZIONE: Il costrutto Para

Sia $(\mathcal{C}, I, \otimes)$ una categoria monoidale strettamente simmetrica. Allora, $\mathbf{Para}_{\otimes}(\mathcal{C})$ è la 2-categoria definita come segue.

- Le 0-celle sono oggetti di \mathcal{C} .
- Le 1-cells sono coppie $(P, f) : A \rightarrow B$, dove $P : \mathcal{C}$ e $f : P \otimes A \rightarrow B$.
- The 2-celle sono $r : (P, f) \Rightarrow (Q, g)$, dove $r : P \rightarrow Q$ è un morfismo in \mathcal{C} che rispetta certe condizioni di naturalità.

Vedasi Gavranović, 2024.

Gradient-based learning con lenti parametriche



Gavranović, 2024


DEFINIZIONE: Il costrutto **Lens**

Sia $(\mathcal{C}, 1, \times)$ una categoria Cartesiana. Allora, **Lens** (\mathcal{C}) è la categoria definita come segue.

- Un oggetto di **Lens** (\mathcal{C}) è una coppia $\left(\begin{smallmatrix} A \\ A' \end{smallmatrix} \right)$ di oggetti di \mathcal{C} .
- Un morfismo $\left(\begin{smallmatrix} A \\ A' \end{smallmatrix} \right) \rightarrow \left(\begin{smallmatrix} B \\ B' \end{smallmatrix} \right)$ (anche chiamato lente) è una coppia $\left(\begin{smallmatrix} f \\ f' \end{smallmatrix} \right)$ di morfismi di \mathcal{C} tali che $f : A \rightarrow B$ and $f' : A \times B' \rightarrow A'$. La mappa f è nota come *forward pass* della lente, mentre la mappa f' è nota come *backward pass*.

Vedasi Cruttwell et al., 2022.

Gradient-based learning con lenti parametriche



Cruttwell et al., 2022

DEFINIZIONE: Cartesian reverse differential category


Una *Cartesian reverse differential category* (CRDC) \mathcal{C} è una categoria Cartesiana con una struttura additiva dove è definito un operatore differenziale R che ha le proprietà di una *reverse derivative*. Si vedano Cockett et al., 2019 e Gavranović, 2024.

ESEMPIO: Smooth

Consideriamo **Smooth**, ovvero la categoria degli spazi Euclidei e delle funzioni lisce. **Smooth** è una CRDC rispetto all'operatore

$$R[f] : (x, y) \mapsto \mathcal{J}_f(x)^T y.$$

Gradient-based learning con lenti parametriche



Cruttwell et al., 2022

Categorical deep learning:

(co)algebre categoriche

come teoria delle architetture

Geometric deep learning

Il *geometric deep learning* è una teoria delle architetture di reti neurali che imita l'*Erlangen Programme*, organizzando le architetture in base al concetto di equivarianza rispetto ad azioni di gruppi (Bronstein et al., 2021).

Categorical deep learning

Il *categorical deep learning* è una teoria delle architetture di reti neurali che generalizza il GDL, organizzando le architetture in base al concetto di omomorfismo di (co)algebre categoriche (Gavranović et al., 2024).

DEFINIZIONE: Algebra su un endofuntore

Sia $F : \mathcal{C} \rightarrow \mathcal{C}$ un endofuntore. Un'algebra su F è una coppia (A, a) dove A è un oggetto di \mathcal{C} e $a : F(A) \rightarrow A$ è un morfismo in \mathcal{C} .

DEFINIZIONE: Omomorfismo di algebre

Siano (A, a) e (B, b) algebre sullo stesso endofuntore $F : \mathcal{C} \rightarrow \mathcal{C}$. Un omomorfismo di algebre $(A, a) \rightarrow (B, b)$ è un morfismo $f : A \rightarrow B$ in \mathcal{C} tale che $F(f) \circ b = a \circ f$.

$$\begin{array}{ccc} T(A) & \xrightarrow{T(f)} & T(B) \\ \downarrow a & & \downarrow b \\ A & \xrightarrow{f} & B \end{array}$$

ESEMPIO: Liste


Sia A un insieme. Consideriamo l'endofuntore $1 + A \times -$ su **Set**. Sia $\text{List}(A)$ l'insieme delle liste di elementi di A . Allora, se $\text{Nil} : 1 \rightarrow \text{List}(A)$ mappa l'unico oggetto di 1 alla lista vuota e $\text{Cons} : A \times \text{List}(A) \rightarrow \text{List}(A)$ aggiunge un elemento a una lista, $(\text{List}(A), [\text{Nil}, \text{Cons}])$, è un algebra su $1 + A \times -$. (Esempio da Gavranović et al., 2024.)

ESEMPIO: List folds

Consideriamo due algebre $(\text{List}(A), [\text{Nil}, \text{Cons}])$ e $(Z, [r_0, r_1])$ su $1 + A \times -$. Un omomorfismo $f : \text{List}(A) \rightarrow Z$ tra queste due algebre deve soddisfare

$$\begin{aligned} f(\text{Nil}) &= r_0, \\ f(\text{Cons}(a, l)) &= r_1(a, f(l)). \end{aligned}$$

Hence, f è necessariamente un *fold* che riduce liste di elementi di A a singoli elementi di Z . (Esempio da Gavranović et al., 2024.)



Gavranović et al., 2024

Prospettive future

C'è una competizione in corso tra varie discipline, che puntano a spiegare le reti neurali utilizzando ciascuna i propri strumenti:

- **fisica matematica** (e.g. Roberts et al., 2022),

C'è una competizione in corso tra varie discipline, che puntano a spiegare le reti neurali utilizzando ciascuna i propri strumenti:

- **fisica matematica** (e.g. Roberts et al., 2022),
- **topologia** (e.g. Hensel et al., 2021),

C'è una competizione in corso tra varie discipline, che puntano a spiegare le reti neurali utilizzando ciascuna i propri strumenti:

- **fisica matematica** (e.g. Roberts et al., 2022),
- **topologia** (e.g. Hensel et al., 2021),
- **probabilità** (e.g. Patel et al., 2015),

C'è una competizione in corso tra varie discipline, che puntano a spiegare le reti neurali utilizzando ciascuna i propri strumenti:

- **fisica matematica** (e.g. Roberts et al., 2022),
- **topologia** (e.g. Hensel et al., 2021),
- **probabilità** (e.g. Patel et al., 2015),
- e così via...

La teoria delle categorie, oltre a offrire strumenti propri, potrebbe creare un ponte tra queste discipline e potrebbe unificare i loro approcci in una teoria generale del deep learning.

Riferimenti bibliografici



Abbott, V. (2023). **Robust Diagrams for Deep Learning Architectures: Applications and Theory** [Tesi di dottorato, Honours Thesis, The Australian National University, Canberra].



Abbott, V. (2024). **Neural Circuit Diagrams: Robust Diagrams for the Communication, Implementation, and Analysis of Deep Learning Architectures.** *arXiv preprint arXiv:2402.05424.*



Abbott, V., & Zardini, G. (2024). **Functor String Diagrams: A Novel Approach to Flexible Diagrams for Applied Category Theory.** *arXiv preprint arXiv:2404.00249.*



Bronstein, M. M., Bruna, J., Cohen, T., & Veličković, P.

(2021). **Geometric deep learning: Grids, groups, graphs, geodesics, and gauges.** *arXiv preprint arXiv:2104.13478*.



Chytas, S. P., Lokhande, V. S., Li, P., & Singh, V. (2024). **Pooling Image Datasets With Multiple Covariate Shift and Imbalance.** *arXiv preprint arXiv:2403.02598*.



Clark, S., & Pulman, S. (2007). **Combining symbolic and distributional models of meaning.** *American Association for Artificial Intelligence*.



Cockett, R., Cruttwell, G., Gallagher, J., Lemay, J.-S. P., MacAdam, B., Plotkin, G., & Pronk, D. (2019). **Reverse derivative categories.** *arXiv preprint arXiv:1910.07065*.



Coecke, B., Sadrzadeh, M., & Clark, S. (2010). **Mathematical foundations for a compositional distributional model of meaning.** *arXiv preprint arXiv:1003.4394*.



Cruttwell, G. S., Gavranović, B., Ghani, N., Wilson, P., & Zanasi, F. (2022). **Categorical foundations of gradient-based learning.** *European Symposium on Programming*.



Dudzik, A. J., & Veličković, P. (2022). **Graph neural networks are dynamic programmers.** *Advances in neural information processing systems*.



Dudzik, A. J., von Glehn, T., Pascanu, R., & Veličković, P. (2024). **Asynchronous algorithmic alignment with cocycles.** *Learning on Graphs Conference*.



Fong, B., & Spivak, D. I. (2018). **Seven sketches in compositionality: An invitation to applied category theory.** *arXiv preprint arXiv:1803.05316*.



Gavranović, B. (2019). **Compositional deep learning.** *arXiv preprint arXiv:1907.08292*.



Gavranović, B. (2024). **Fundamental Components of Deep Learning: A category-theoretic approach.** *arXiv preprint arXiv:2403.13001.*



Gavranović, B., Lessard, P., Dudzik, A. J., von Glehn, T., Araújo, J. G. M., & Veličković, P. (2024). **Position: Categorical Deep Learning is an Algebraic Theory of All Architectures.** *Forty-first International Conference on Machine Learning.*



Hensel, F., Moor, M., & Rieck, B. (2021). **A survey of topological machine learning methods.** *Frontiers in Artificial Intelligence.*



Khatri, N., Laakkonen, T., Liu, J., & Wang-Maścianica, V. (2024). **On the Anatomy of Attention.** *arXiv preprint arXiv:2407.02423.*



Lewis, M. (2019). **Compositionality for recursive neural networks.** *arXiv preprint arXiv:1901.10723.*



Olah, C., & Carter, S. (2017). **Research Debt** [<https://distill.pub/2017/research-debt>]. *Distill.*



Patel, A. B., Nguyen, T., & Baraniuk, R. G. (2015). **A probabilistic theory of deep learning.** *arXiv preprint arXiv:1504.00641.*



Raff, E. (2019). **A step toward quantifying independently reproducible machine learning research.** *Advances in Neural Information Processing Systems.*



Rahimi, A. (2017). **Machine Learning has become alchemy** [<https://www.youtube.com/watch?v=x7psGHgatGM>].



Roberts, D. A., Yaida, S., & Hanin, B. (2022). **The principles of deep learning theory.** Cambridge University Press
Cambridge, MA, USA.



Sheshmani, A., & You, Y.-Z. (2021). **Categorical representation learning: morphism is all you need.** *Machine Learning: Science and Technology*.